

## Relazione Prima Esercitazione in SAS

Autori: Cerasoli Giovanni Giacomo, Ricchebono Alessandro, Tacchella Matteo

L'obiettivo della relazione è studiare come l'insieme di alcune variabili, relative alla psicologia di uno studente, si relaziona ad una variabile categorica ed alle variabili restanti, relative a risultati accademici. Si effettuano un'analisi descrittiva ed un modello lineare di analisi della covarianza.

### Analisi del dataset:

La relazione è relativa a dati raccolti per 600 studenti delle scuole superiori su 7 variabili, di cui tre psicologiche, tre accademiche (punteggi di test standardizzati) ed una riferita al programma educativo in cui si trova l'alunno:

- locus\_of\_control: padronanza di sé
- self\_concept: concetto di sé
- motivation: motivazione
- read: lettura
- write: scrittura
- science: scienze
- program type: tipo di programma

Tutte le variabili sono numeriche, ad esclusione di program type, che è categorica ed assume valori 1, 2, 3, riferiti rispettivamente ai programmi generale, accademico, professionale. Non ci sono valori mancanti.

Si rileva che gli studenti non sono equidistribuiti nelle tre categorie di program type, ma circa il 45% appartiene al livello 2; per i restanti, il 23% è del programma 1 e circa il 32% del 3 (tabella 1). L'esperimento non è quindi bilanciato.

| program type |           |             |                      |                        |
|--------------|-----------|-------------|----------------------|------------------------|
| PROG         | Frequenza | Percentuale | Frequenza cumulativa | Percentuale cumulativa |
| 1            | 138       | 23.00       | 138                  | 23.00                  |
| 2            | 271       | 45.17       | 409                  | 68.17                  |
| 3            | 191       | 31.83       | 600                  | 100.00                 |

Tabella 1 - frequenze assolute e relative e frequenze cumulate per programma

Si riportano anche media, deviazione standard, minimo e massimo delle variabili numeriche (tabella 2):

| Variabile        | N   | Media      | Dev std    | Minimo     | Massimo    |
|------------------|-----|------------|------------|------------|------------|
| READ             | 600 | 51.9018333 | 10.1029831 | 24.6200066 | 80.5864944 |
| WRITE            | 600 | 52.3848332 | 9.7264550  | 20.0688801 | 83.9348221 |
| SCIENCE          | 600 | 51.7633331 | 9.7061791  | 21.9895325 | 80.3694153 |
| LOCUS_OF_CONTROL | 600 | 0.0965333  | 0.6702799  | -1.9959567 | 2.2055113  |
| MOTIVATION       | 600 | 0.0038979  | 0.8224000  | -2.7466691 | 2.5837522  |
| SELF_CONCEPT     | 600 | 0.0049167  | 0.7055125  | -2.5327499 | 2.0935633  |

Tabella 2 - media, deviazione standard, minimo e massimo

Si osserva come i range, le medie e le deviazioni standard delle variabili accademiche siano piuttosto simili. Per le variabili psicologiche si nota che la media di locus\_of\_control è significativamente più alta rispetto a quelle di motivation e self\_concept; infatti, il minimo della prima è più alto rispetto a quelle delle altre due, mentre i massimi non si discostano più di tanto.

Dai boxplot per programma (figura 1) relativi ad ogni altra variabile si riscontra che, in tutti i casi, i box riferiti al programma 1 sono leggermente più bassi, quelli al programma 3 sono più in alto, mentre gli altri si trovano nel mezzo; questo fatto si nota soprattutto per le variabili psicologiche. Tuttavia, la variazione dei valori è poco significativa.




Figura 1

Dalla tabella dei coefficienti di correlazione (tabella 3) si evince che le variabili accademiche sono tra loro moderatamente correlate, mentre le variabili psicologiche sono debolmente correlate fra di loro (indici < 0.3). La variabile self\_concept non è correlata con read, write e science (tutti gli indici minori di 0.1), a differenza di motivation e locus\_of\_control; quest'ultima ha coefficienti di correlazione compresi tra 0.3 e 0.4 con tre le variabili accademiche, mentre motivation li ha compresi tra 0.1 e 0.3.

| Coefficienti di correlazione di Pearson, N = 600 |              |                  |            |         |         |         |
|--------------------------------------------------|--------------|------------------|------------|---------|---------|---------|
|                                                  | SELF_CONCEPT | LOCUS_OF_CONTROL | MOTIVATION | WRITE   | READ    | SCIENCE |
| SELF_CONCEPT                                     | 1.00000      | 0.17119          | 0.28857    | 0.01945 | 0.06066 | 0.06983 |
| LOCUS_OF_CONTROL                                 | 0.17119      | 1.00000          | 0.24513    | 0.35888 | 0.37357 | 0.32463 |
| MOTIVATION                                       | 0.28857      | 0.24513          | 1.00000    | 0.25425 | 0.21061 | 0.11567 |
| WRITE                                            | 0.01945      | 0.35888          | 0.25425    | 1.00000 | 0.62859 | 0.56915 |
| READ                                             | 0.06066      | 0.37357          | 0.21061    | 0.62859 | 1.00000 | 0.69069 |
| SCIENCE                                          | 0.06983      | 0.32463          | 0.11567    | 0.56915 | 0.69069 | 1.00000 |

Tabella 3 - Coefficienti di correlazione di Pearson

Si riportano gli scatterplot di self\_concept – write (figura 2) e locus\_of\_control – write (figura 3) che sono, rispettivamente, le coppie di variabili con coefficiente di correlazione più basso e più alto, prendendone una da quelle psicologiche ed una da quelle accademiche. In entrambi i grafici sono evidenziati i tipi di programma.




Figura 2

Si nota come la nuvola di punti sia dispersiva e come il tipo di programma non influisca sui valori assunti da ogni singola unità. Conferma il basso coefficiente di correlazione.

Si riscontra che la nuvola di punti segue un andamento più lineare rispetto al caso precedente, ma anche in questa casistica il tipo di programma non sembra influente.




Figura 3

## Analisi della covarianza:

Le variabili risposta considerate sono le variabili psicologiche (self\_concept, motivation, locus\_of\_control) in dipendenza dalle variabili accademiche (write, read, science) e dal fattore tipo di programma.

Viene quindi effettuata un'analisi univariata per le tre variabili psicologiche: in tutti i casi si ha un indice  $R^2$  piccolo (il più elevato è circa 0.19), per cui ne consegue che non si riuscirà a predire con precisione i valori delle variabili psicologiche. Tuttavia, i p-value riferiti ai valori F sono molto piccoli (tutti inferiori a 0.0001): i risultati dovrebbero quindi essere differenti per i diversi livelli di program type e per i valori delle variabili accademiche.

Si allega ad esempio l'output riferito alla variabile locus\_of\_control:

| La procedura GLM                       |     |                    |                  |          |        |
|----------------------------------------|-----|--------------------|------------------|----------|--------|
| Variabile dipendente: LOCUS_OF_CONTROL |     |                    |                  |          |        |
| Origine                                | DF  | Somma dei quadrati | Media quadratica | Valore F | Pr > F |
| Modello                                | 5   | 50.2595509         | 10.0519102       | 27.28    | <.0001 |
| Errore                                 | 594 | 218.8562365        | 0.3684448        |          |        |
| Totale corretto                        | 599 | 269.1157874        |                  |          |        |

| R-quadro | Coeff var | Radice MSE | Media di LOCUS_OF_CONTROL |
|----------|-----------|------------|---------------------------|
| 0.186758 | 628.7948  | 0.606997   | 0.096533                  |

Si riportano i risultati dell'analisi con i metodi di somma dei quadrati 1 e 3 per tutte le variabili psicologiche (tabelle 4 – 9). Osservando le colonne Pr>F, si riscontra che, con entrambi i metodi SS1 e SS3, nessuna delle variabili accademiche influisce sul valore di self\_concept; per quanto riguarda locus\_of\_control, si rileva che la sola variabile science non è statisticamente significativa per il modello. Nel caso di motivation con entrambi i metodi si scarta la variabile science, ma il p-value di write aumenta in modo considerevole passando da SS1 a SS3.

| La procedura GLM                   |    |             |                  |          |        |  |
|------------------------------------|----|-------------|------------------|----------|--------|--|
| Variabile dipendente: SELF_CONCEPT |    |             |                  |          |        |  |
| Origine                            | DF | SS Tipo I - | Media quadratica | Valore F | Pr > F |  |
| PROG                               | 2  | 14.69575239 | 7.34787620       | 15.48    | <.0001 |  |
| READ                               | 1  | 0.30379273  | 0.30379273       | 0.64     | 0.4241 |  |
| SCIENCE                            | 1  | 0.52064084  | 0.52064084       | 1.10     | 0.2955 |  |
| WRITE                              | 1  | 0.59051932  | 0.59051932       | 1.24     | 0.2652 |  |

| Origine | DF | SS Tipo III - | Media quadratica | Valore F | Pr > F |  |
|---------|----|---------------|------------------|----------|--------|--|
| PROG    | 2  | 14.21838537   | 7.10919268       | 14.97    | <.0001 |  |
| READ    | 1  | 0.04557875    | 0.04557875       | 0.10     | 0.7568 |  |
| SCIENCE | 1  | 0.78237876    | 0.78237876       | 1.65     | 0.1998 |  |
| WRITE   | 1  | 0.59051932    | 0.59051932       | 1.24     | 0.2652 |  |

Tabelle 4 - 5

La procedura GLM  
Variabile dipendente: LOCUS\_OF\_CONTROL

| Origine | DF | SS          | Tipo I - | Media quadratica | Valore F | Pr > F |
|---------|----|-------------|----------|------------------|----------|--------|
| PROG    | 2  | 9.59130731  |          | 4.79565365       | 13.02    | <.0001 |
| READ    | 1  | 33.61697577 |          | 33.61697577      | 91.24    | <.0001 |
| SCIENCE | 1  | 2.32602483  |          | 2.32602483       | 6.31     | 0.0122 |
| WRITE   | 1  | 4.72524304  |          | 4.72524304       | 12.82    | 0.0004 |

| Origine | DF | SS         | Tipo III - | Media quadratica | Valore F | Pr > F |
|---------|----|------------|------------|------------------|----------|--------|
| PROG    | 2  | 5.02961991 |            | 2.51480995       | 6.83     | 0.0012 |
| READ    | 1  | 4.16815963 |            | 4.16815963       | 11.31    | 0.0008 |
| SCIENCE | 1  | 0.92248638 |            | 0.92248638       | 2.50     | 0.1141 |
| WRITE   | 1  | 4.72524304 |            | 4.72524304       | 12.82    | 0.0004 |

Tabelle 6 - 7

La procedura GLM  
Variabile dipendente: MOTIVATION

| Origine | DF | SS          | Tipo I - | Media quadratica | Valore F | Pr > F |
|---------|----|-------------|----------|------------------|----------|--------|
| PROG    | 2  | 38.11663952 |          | 19.05831976      | 32.87    | <.0001 |
| READ    | 1  | 12.20453223 |          | 12.20453223      | 21.05    | <.0001 |
| SCIENCE | 1  | 0.59558373  |          | 0.59558373       | 1.03     | 0.3112 |
| WRITE   | 1  | 9.85052717  |          | 9.85052717       | 16.99    | <.0001 |

| Origine | DF | SS          | Tipo III - | Media quadratica | Valore F | Pr > F |
|---------|----|-------------|------------|------------------|----------|--------|
| PROG    | 2  | 30.18084209 |            | 15.09042104      | 26.03    | <.0001 |
| READ    | 1  | 2.49445035  |            | 2.49445035       | 4.30     | 0.0385 |
| SCIENCE | 1  | 2.25173630  |            | 2.25173630       | 3.88     | 0.0492 |
| WRITE   | 1  | 9.85052717  |            | 9.85052717       | 16.99    | <.0001 |

Tabelle 8 - 9

Dalle tabelle delle stime dei parametri (viene riportata solo quella relativa a locus\_of\_control, tabella 10) si nota nuovamente come science sia poco influente sul valore predetto di locus\_of\_control: infatti, l'incremento riferito a science per un'unità è di circa 0.005 nel valore predetto di locus\_of\_control.

| Parametro | Stima        |   | Errore standard | Valore t | Pr >  t |
|-----------|--------------|---|-----------------|----------|---------|
| Intercept | -1.373094234 | B | 0.16259260      | -8.44    | <.0001  |
| PROG 1    | -0.251670509 | B | 0.06846988      | -3.68    | 0.0003  |
| PROG 2    | -0.123875431 | B | 0.05760714      | -2.15    | 0.0319  |
| PROG 3    | 0.000000000  | B | .               | .        | .       |
| READ      | 0.012504619  |   | 0.00371779      | 3.36     | 0.0008  |
| SCIENCE   | 0.005761477  |   | 0.00364116      | 1.58     | 0.1141  |
| WRITE     | 0.012145048  |   | 0.00339136      | 3.58     | 0.0004  |

Tabella 10 - Stime dei parametri per locus\_of\_control

Le tabelle seguenti (11 – 14) mostrano i risultati dei test per l'ipotesi di nessun effetto delle variabili accademiche e program. Si rilevano le stesse conclusioni dell'analisi precedente: la variabile science, avendo p-value maggiori di 0.01, è l'unica statisticamente non significativa per il modello. Si nota anche che la variabile read è meno significativa rispetto alle restanti, avendo p-value uguale a 0.0027.

Criteri di test MANOVA e approssimazioni F per l'ipotesi di nessun effetto PROG globale  
H = Tipo III - Matrice SSCP per PROG  
E = Matrice SSCP di errore

S=2 M=0 N=295

| Statistica               | Valore     | Valore F | DF num | DF den | Pr > F |
|--------------------------|------------|----------|--------|--------|--------|
| Lambda di Wilks          | 0.89143832 | 11.67    | 6      | 1184   | <.0001 |
| Traccia di Pillai        | 0.10864869 | 11.35    | 6      | 1186   | <.0001 |
| Traccia Hotelling-Lawley | 0.12168500 | 12.00    | 6      | 787.56 | <.0001 |
| Radice massima di Roy    | 0.12087752 | 23.89    | 3      | 593    | <.0001 |

NOTE: la statistica F per la radice massima di Roy è un limite superiore.

NOTE: la statistica F per Lambda di Wilks è esatta.

Tabella 11

Criteri di test MANOVA e statistiche F esatte per l'ipotesi di nessun effetto READ globale  
H = Tipo III - Matrice SSCP per READ  
E = Matrice SSCP di errore

S=1 M=0.5 N=295

| Statistica               | Valore     | Valore F | DF num | DF den | Pr > F |
|--------------------------|------------|----------|--------|--------|--------|
| Lambda di Wilks          | 0.97642519 | 4.76     | 3      | 592    | 0.0027 |
| Traccia di Pillai        | 0.02357481 | 4.76     | 3      | 592    | 0.0027 |
| Traccia Hotelling-Lawley | 0.02414400 | 4.76     | 3      | 592    | 0.0027 |
| Radice massima di Roy    | 0.02414400 | 4.76     | 3      | 592    | 0.0027 |

Tabella 12

Criteri di test MANOVA e statistiche F esatte per l'ipotesi di nessun effetto SCIENCE globale  
H = Tipo III - Matrice SSCP per SCIENCE  
E = Matrice SSCP di errore

S=1 M=0.5 N=295

| Statistica               | Valore     | Valore F | DF num | DF den | Pr > F |
|--------------------------|------------|----------|--------|--------|--------|
| Lambda di Wilks          | 0.98340548 | 3.33     | 3      | 592    | 0.0193 |
| Traccia di Pillai        | 0.01659452 | 3.33     | 3      | 592    | 0.0193 |
| Traccia Hotelling-Lawley | 0.01687455 | 3.33     | 3      | 592    | 0.0193 |
| Radice massima di Roy    | 0.01687455 | 3.33     | 3      | 592    | 0.0193 |

Tabella 13

Criteri di test MANOVA e statistiche F esatte per l'ipotesi di nessun effetto WRITE globale  
H = Tipo III - Matrice SSCP per WRITE  
E = Matrice SSCP di errore

S=1 M=0.5 N=295

| Statistica               | Valore     | Valore F | DF num | DF den | Pr > F |
|--------------------------|------------|----------|--------|--------|--------|
| Lambda di Wilks          | 0.94739400 | 10.96    | 3      | 592    | <.0001 |
| Traccia di Pillai        | 0.05260600 | 10.96    | 3      | 592    | <.0001 |
| Traccia Hotelling-Lawley | 0.05552705 | 10.96    | 3      | 592    | <.0001 |
| Radice massima di Roy    | 0.05552705 | 10.96    | 3      | 592    | <.0001 |

Tabella 14

In conclusione, si è notato come ci sia una debole relazione tra le variabili psicologiche e quelle accademiche ed il tipo di programma. Il modello evidenzia questa relazione, pur non manifestando evidenti risultati, come indici  $R^2$  bassi. Si è osservato anche che i risultati cambiano lievemente al variare del tipo di programma.